

# 数值最优化实验报告：多种线搜索算法的实现和比较

15336134 莫凡

2017 年 10 月 30 日

## 摘要

本文是中山大学 2015 级信息与计算科学专业的运筹学与最优化课程作业 [1]。内容为使用各种基于线搜索的牛顿方法实现对 Waston 函数 [2] 的优化。本文主要使用 MATLAB R2016b 实现并对比了非精确线搜索的 (Strong) Wolfe 准则、Wolfe 准则、Goldstein 准则与 armijo 准则，应用了最速下降法、阻尼牛顿法、LM 方法、拟牛顿法（SR1 公式、DFP 公式、BFGS 公式）测量了  $n=6,9,12$  的情形。

为了保证算法的正确性，本文同时根据 [2] 的建议，实现了两个小函数用来检验算法的正确性。通过实验，发现阻尼牛顿法、LM 方法、SR1 公式、BFGS 公式均能达到预期的收敛效果，而 DFP 公式和最速下降法没有在指定迭代次数内收敛。对比多种线搜索步长方法，使用强 Wolfe 准则是相对效果较为出色的方案。

# 目录

<b>1</b>	<b>问题的分析与重述</b>	<b>3</b>
1.1	环境与假设 . . . . .	3
1.2	Watson 函数的定义与计算 . . . . .	3
<b>2</b>	<b>测试环节</b>	<b>5</b>
2.1	三个测试函数 . . . . .	5
2.1.1	Rosenbrock function . . . . .	5
2.1.2	Freudenstein-and-Roth function . . . . .	5
2.1.3	Powell-badly-scaled function . . . . .	6
2.2	辅助软件检测 . . . . .	6
<b>3</b>	<b>线搜索程序</b>	<b>6</b>
3.1	定步长 . . . . .	6
3.2	精确线搜索 . . . . .	6
3.3	非精确线搜索 . . . . .	6
3.3.1	Arojio Condition . . . . .	7
3.3.2	Wolfe Condition . . . . .	7
3.3.3	Strong Wolfe Condition . . . . .	7
3.3.4	Goldstein Condition . . . . .	7
<b>4</b>	<b>优化算法</b>	<b>8</b>
4.1	阻尼牛顿法 . . . . .	8
<b>5</b>	<b>实验与结果</b>	<b>8</b>
<b>6</b>	<b>后记</b>	<b>8</b>
6.1	需要改进的实验内容 . . . . .	8
6.2	实验过程 . . . . .	8
	<b>参考文献</b>	<b>9</b>

# 1 问题的分析与重述

## 1.1 环境与假设

本次试验主要在 Windows8.1 Home Basic 操作系统下，使用 MATLAB R2016b 完成。为了对于函数值与梯度进行检验，也同时用到了以下软件或程序包

- R 3.3.4
- Wolfram Mathematica 10

本文所涉及的所有代码与参考文献（如果能搜集到电子版）全部托管在 <https://github.com/w007878/watson>，以 MIT 协议发布

本文所完成的任务，是通过基于线搜索的迭代方法，求得一个函数在定义域上的数值极小值。由于函数的复杂性，我们无法验证此极小值是否为全局最小值，只能借助文献 [2] 中的参考值来检验结果的正确性。

为了评估一项算法，我们采用一下几个指标

1. 算法是否在规定迭代次数内收敛，如果是，需要迭代多少步
2. 算法停止后（包括满足梯度条件或者迭代次数条件终止）是否得到正确的极小值
3. 函数调用了多少次
4. MATLAB 的 cputime

## 1.2 Watson 函数的定义与计算

考虑以下定义在  $n$  维空间上的实值函数

$$f(x) = \sum_{i=1}^m r_i^2(x)$$

其中  $n, m, r_i$  可以是各种各样的取值。现要实现一个优化算法，求解这个函数的极小值。

本次试验的主要任务是实现

$$r_i(x) = \sum_{j=2}^n (j-1) x_j t_i^{j-2} - \left( \sum_{j=1}^n x_j t_i^{j-1} \right)^2 - 1$$

的情况。除此之外，还要有

$$m = 31 \quad 2 \leq n \leq 31$$

$$t_i = \frac{i}{29} \quad 1 \leq i \leq 29$$

$$r_{30}(x) = x_1 \quad r_{31}(x) = x_2 - x_1^2 - 1$$

这个函数被称为 Watson 函数 [3]，是我们要优化的目标。首先我们要得到的就是它的梯度与 Hessian 矩阵的表达式。事实上，我们没有必要写出  $\nabla f$  关于自变量  $x$  的表达式，而是用  $r(x)$  和它的偏导数进行代替

$$\frac{\partial f}{\partial x_k} = 2 \sum_{i=1}^m r_i(x) \frac{\partial r_i}{\partial x_k}$$

刨除最后两项不优美的式子，我们有

$$\frac{\partial f}{\partial x_k} = \sum_{i=1}^m \frac{\partial f}{\partial r_i} \frac{\partial r_i}{\partial x_k}$$

其中

$$\frac{\partial r_i}{\partial x_k} = (k-1) t_i^{k-2} - 2 \left( \sum_{j=1}^n x_j t_i^{j-1} \right) t_i^{k-1}$$

为了在代码中计算出这个东西，我们构造两个辅助矩阵。（为简单起见，用  $m$  代替 29）

$$T_1 = \begin{bmatrix} t_1^0 & t_1^1 & \cdots & t_1^{n-1} \\ t_2^0 & & \cdots & t_2^{n-1} \\ \cdots & \cdots & \cdots & \cdots \\ t_m^0 & \cdots & \cdots & t_m^{n-1} \end{bmatrix} \quad T_2 = \begin{bmatrix} 0 & t_1^0 & t_1^1 & \cdots & t_1^{n-2} \\ 0 & t_2^0 & & \cdots & t_2^{n-2} \\ & \cdots & \cdots & \cdots & \cdots \\ 0 & t_m^0 & \cdots & \cdots & t_m^{n-2} \end{bmatrix}$$

得到 MATLAB 代码

```
01 tmp1 = 4 * T1' * (r(1:29) .* (T1 * x));
02 tmp2 = 2 * (0:n-1)' .* (T2' * r(1:29));
03 grad = tmp2 - tmp1;
```

然后根据  $r_{30}$  与  $r_{31}$  两项，单独处理一下  $\frac{\partial f}{\partial x_1}$  与  $\frac{\partial f}{\partial x_2}$ ，梯度就计算完成了  
接下来是 Hessian 矩阵。有表达式

$$\frac{\partial^2 f}{\partial x_b \partial x_a} = 2 \sum_{i=1}^m \left( \frac{\partial r_i}{\partial x_b} \frac{\partial r_i}{\partial x_a} + \frac{\partial^2 r_i}{\partial x_b \partial x_a} r_i(x) \right)$$

这时我们采用最简单暴力的方法单独计算每一项偏导数以得到矩阵

```
01 prz = (0:n-1) .* T2 - 2 * (T1 * x) .* T1;
02 for a = 1:n
03     for b = 1:n
04         H(a, b)=2*prz(:,a)'*prz(:,b)+2*(-2*power(t,a+b-2))*r(1:29);
05     end
06 end
```

代码中的 `prz` 表示的是每个  $r$  对每个  $x$  的偏导数。

通过对计算复杂度的分析，我们发现计算函数值、梯度和 Hessian 矩阵并没有很大的区别。同时，梯度和 Hessian 矩阵都需要用到相同的中间变量。而由于  $n$  很小，所以这点复杂度的差别基本忽略不计，于是使用一个函数同时计算出他的函数值、梯度与 Hessian 矩阵。

## 2 测试环节

### 2.1 三个测试函数

为了验证优化算法的正确性，在使用它优化 Watson 函数之前使用几个简单的函数进行测试。

这几个函数都具有  $f(x) = \sum_{i=1}^m r_i^2(x)$  的形式。

#### 2.1.1 Rosenbrock function

Rosenbrock function[4] 满足

$$\begin{aligned} n &= 2 \quad m = 2 \\ r_1(x) &= 10(x_2 - x_1^2) \\ r_2(x) &= 1 - x_1 \end{aligned}$$

若以点  $(-1.2, 1)$  作为迭代起点，这个函数应当收敛到点  $(1, 1)$ ,  $f = 0$

#### 2.1.2 Freudenstein-and-Roth function

Freudenstein-and-Roth function[5] 满足

$$\begin{aligned} n &= 2 \quad m = 2 \\ r_1(x) &= -13 + x_1 + ((5 - x_2)x_2 - 2)x_2 \\ r_2(x) &= -29 + x_1 + ((x_2 + 1)x_2 - 14)x_2 \end{aligned}$$

若以点  $(0.5, -2)$  作为迭代起点，可能会得到 1. 局部极小值  $(11.41 \dots, -0.8968 \dots)$ ,  $f = 48.9842$  2. 全局最小值  $(5, 4)$ ,  $f = 0$

#### 2.1.3 Powell-badly-scaled function

Powell-badly-scaled function[6] 满足

$$\begin{aligned} n &= 2 \quad m = 2 \\ r_1(x) &= 10^4 x_1 x_2 - 1 \\ r_2(x) &= e^{-x_1} + e^{-x_2} - 1.0001 \end{aligned}$$

若以点  $(0, 1)$  作为迭代起点，应当得到极小值  $(1.908 \dots \cdot 10^{-5}, 9.106 \dots)$ ,  $f = 0$

## 2.2 辅助软件检测

使用 R 语言检车 Watson 函数的数值，用它的 numDeriv 包检测 MATLAB 程序中计算的梯度和 Hessian 矩阵的数值。

使用 Mathematica 来检查以上三个测试函数的梯度与 Hessian 矩阵的解析形式是否正确。

## 3 线搜索程序

假设  $d$  是线搜索下降方向 (Newton/quasi-Newton 方向)，我们要求得正实数  $\alpha$ ，使得  $f(x_k + \alpha d) \leq f(x_k)$ ，然后更新  $x_{k+1} = x_k + \alpha d$

线搜索的程序都比较简单。所以不需要进行额外的测验。实现之后可以直接用于后文中的优化算法。

### 3.1 定步长

基本牛顿方法直接设步长  $\alpha = 1$ 。如果采用这种方式，应当将下降方向向量正则化之后再应用。

### 3.2 精确线搜索

令

$$\alpha = \arg \min_{\alpha} f(x_k + \alpha d)$$

这里直接使用 MATLAB 内置的优化函数

### 3.3 非精确线搜索

我们使用最常规的“回溯法”求得非精确线搜索步长。伪代码如下

LINEAR-SEARCH( $\rho, \epsilon, \alpha_0$ )

```
1   $\alpha = \alpha_0$ 
2  while not IS-SATISFY-CONDITION( $\alpha$ )
3       $\alpha = \rho\alpha$ 
4      if  $\alpha < \epsilon$ 
5          return  $\alpha$ 
6  return  $\alpha$ 
```

其中  $\epsilon$  是用于限制步长不应小于某个数的阈值，以防算法收敛速度过慢。代码中使用了  $10^{-5}$ 。 $\rho$  是用于更新  $\alpha$  的值，在实践中取了 0.99 0.999 0.99999999，事实证明因为下降的速度是指数，所以没有太大关系

### 3.3.1 Arojio Condition

$$f(x_k + \alpha p_k) \leq f(x_k) + c\alpha p_k^T \nabla f(x_k)$$

### 3.3.2 Wolfe Condition

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$$

$$\nabla f(x_k + \alpha p_k)^T p_k \geq c_2 \nabla f(x_k)^T p_k$$

### 3.3.3 Strong Wolfe Condition

$$f(x_k + \alpha p_k) \leq f(x_k) + c_1 \alpha \nabla f(x_k)^T p_k$$

$$|\nabla f(x_k + \alpha p_k)^T p_k| \leq c_2 |\nabla f(x_k)^T p_k|$$

根据前人的经验 [7], Arojio 准则中的  $c$ 、(Strong) Wolfe 准则中的  $c_1$  取值  $10^{-4}$ , (Strong) Wolfe 准则中的  $c_2$  取值 0.9, 可以得到更好的步长效果

### 3.3.4 Goldstein Condition

$$f(x_k) + (1 - c) \nabla f(x_k)^T p_k \alpha \leq f(x_k + \alpha p_k) \leq f(x_k) + c \nabla f(x_k)^T p_k \alpha$$

根据 [8] 与 [9] 的建议, 使用线搜索的 Newton 类方法较为常用的是满足 (Strong) Wolfe Condition 的非精确步长。

## 4 优化算法

### 4.1 阻尼牛顿法

牛顿方向是

$$d = -G^{-1}g$$

其中  $G$  是 Hessian 矩阵,  $g$  是梯度

阻尼牛顿法是在牛顿方向上, 通过先搜索得到合适的步长, 然后进行迭代。迭代停止的条件为

## 5 实验与结果

## 6 后记

### 6.1 需要改进的实验内容

### 6.2 实验过程



## 参考文献

- [1] 高立. 数值最优化方法, 2014.
- [2] Jorge J. Moré, Burton S. Garbow, and Kenneth E. Hillstom. Testing unconstrained optimization software. *ACM Trans. Math. Softw.*, 7(1):17–41, March 1981.
- [3] John E Dennis Jr and Robert B Schnabel. *Numerical methods for unconstrained optimization and nonlinear equations*. SIAM, 1996.
- [4] H. H. Rosenbrock. An automatic method for finding the greatest or least value of a function. *The Computer Journal*, 3(3):175–184, 1960.
- [5] Ferdinand Freudenstein and Bernhard Roth. Numerical solution of systems of nonlinear equations. *Journal of the ACM (JACM)*, 10(4):550–556, 1963.
- [6] M. J. D. Powell. A hybrid method for nonlinear equations. In P. Rabinowitz, editor, *Numerical Methods for Nonlinear Algebraic Equations*. Gordon and Breach, 1970.
- [7] Jean Charles Gilbert and Claude Lemaréchal. Some numerical experiments with variable-storage quasi-newton algorithms. *Mathematical programming*, 45(1):407–435, 1989.
- [8] David F Shanno. Conditioning of quasi-newton methods for function minimization. *Mathematics of computation*, 24(111):647–656, 1970.
- [9] Jianzhong Zhang and Chengxian Xu. Properties and numerical performance of quasi-newton methods with modified quasi-newton equations. *Journal of Computational and Applied Mathematics*, 137(2):269 – 278, 2001.